

Unidad 1. Regresión lineal simple y correlación

Medidas de dispersión

Suma de los cuadrados de las desviaciones de los valores de X con respecto a su media:

$$S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2$$

Suma de los productos de las desviaciones de los valores de X y Y con respecto a sus medias:

$$S_{xy} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

Suma de los cuadrados de las desviaciones de los valores de Y con respecto a su media:

$$S_{yy} = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Coeficiente de correlación y de determinación

Coeficiente de correlación de Pearson:

$$r = \frac{S_{xy}}{\sqrt{S_{xx} \cdot S_{yy}}}$$

Coeficiente de determinación:

$$r^2$$

Recta de regresión ajustada

La regresión lineal ajustada se representa mediante estadísticos:

$$\hat{Y} = b_0 + b_1 X$$

donde $\hat{Y}$ representa el valor de Y obtenido mediante la recta de regresión ajustada (no la verdadera Y). Los estadísticos b_0 y b_1 se calculan de la siguiente manera:

$$b_1 = \frac{S_{xy}}{S_{xx}}$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

Cálculo de residuales

Residuales:

$$e_i = Y_i - \hat{Y}_i$$

Sumas de cuadrados SS (Sum of Squares)

Suma de los Cuadrados de los Errores:

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n e_i^2$$

Suma total de cuadrados:

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Suma de cuadrados de regresión:

$$SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

- SST: Mide la variabilidad total de los datos observados.
- SSR: Mide la variabilidad de los datos que el modelo de regresión explica.
- SSE: Mide la variabilidad no explicada por el modelo (es decir, los residuos).

Intervalo de confianza

Estadístico de prueba t :

$$t = \frac{b_1}{SE(b_1)}$$

Error estándar de b_1 :

$$SE(b_1) = \frac{\sqrt{SSE/(n-2)}}{\sqrt{S_{xx}}}$$

o

$$SE(b_1) = \frac{\sqrt{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2 / (n-2)}}{\sqrt{S_{xx}}}$$

Intervalo de confianza para b_1 :

$$\hat{b}_1 - t_{\alpha/2} \cdot SE(b_1) < \beta_1 < \hat{b}_1 + t_{\alpha/2} \cdot SE(b_1)$$

donde n representa la cantidad de pares de datos.

Comprobación de supuestos

Comprobar suposiciones:

- Test de shapiro a los residuales e_i : Para comprobar si la distribución es normal sobre la recta.
- Grafico X vs Y : Para observar si los datos soportan la suposición de linealidad.
- Gráfico de residuales: Para observar si los datos soportan la suposición de linealidad, complementario al coeficiente de correlación
- Test de Breusch-Pagan: Para detectar heteroscedasticidad en regresion lineal

Test de Shapiro:

```
from scipy.stats import shapiro
```

Después, se obtiene el valor-p:

```
_, valor_p_sh = shapiro(data)
```

- H_0 : Los datos siguen una distribución normal
- H_1 : Los datos no siguen una distribución normal

Test de Breusch-Pagan:

```
from statsmodels.stats.api import het_breuschpagan
```

Después, se obtiene el valor-p:

```
_, valor_p_bp, _, _ = het_breuschpagan(residuales, X)
```

- H_0 : Hay homoscedasticidad
- H_1 : Hay heteroscedasticidad

ANOVA en regresión lineal

Fuente de variación	Suma de cuadrados (SS)	Grados de libertad (df)	Promedio de los cuadrados (MS)	Estadístico F
Regresión	\$ SSR\$	p	$MSR = \frac{SSR}{p}$	$F = \frac{MSR}{MSE}$
Error	SSE	$n - p - 1$	$MSE = \frac{SSE}{n - p - 1}$	
Total	$SSST$	$n - 1$		

donde p es el número de parámetros para la recta de regresión ajustada (en la regresión simple $p = 1$). Las hipótesis son:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

Problemario de la Unidad 1

Problema 1

Un profesor intenta mostrar a sus estudiantes la importancia de los exámenes cortos, aun cuando el 90% de la calificación final esté determinada por los exámenes parciales. Él cree que cuanto más altas sean las calificaciones de los exámenes cortos, más alta será la calificación final. Seleccionó una muestra aleatoria de 15 estudiantes de su clase con los siguientes datos:

Promedio de exámenes cortos	Promedio final
59	64
92	84
72	77
90	80
95	77
87	81
89	80
77	84
76	80
65	69
97	83
42	40
94	78
62	65
91	90

- Establezca una variable dependiente (Y) y una variable independiente (X).
1. Establezca una variable dependiente (Y) y una variable independiente (X). x es el promedio de los exámenes y y es el promedio final
- Realice un diagrama de dispersión para estos datos.
- ¿Los datos soportan la suposición de linealidad? Sí, los datos soportan la suposición de linealidad. En el diagrama se observa que los puntos siguen una tendencia ascendente constante, a pesar de notarse un inicio de curvatura en el lado derecho,

no es suficiente para asumir que es sistemática, por tanto, no se descarta la linealidad. Esto indica que una línea recta es un modelo adecuado para describir la relación entre el promedio de exámenes cortos y el promedio final.

4. Calcule el coeficiente de correlación e interprete el resultado. El coeficiente de correlación obtenido es de 0.8646, lo que indica una correlación positiva y fuerte entre el promedio de exámenes cortos y el promedio final. A medida que aumenta el promedio de exámenes cortos, el promedio final también tiende a aumentar. Este resultado es consistente con el patrón ascendente observado en el diagrama de dispersión.
5. Calcule el coeficiente de determinación e interprete el resultado. es $R^2 = 74.75\%$ El coeficiente de determinación obtenido fue de 74.75%, lo que indica que el 74.75% de la variabilidad en el promedio final de los estudiantes puede ser explicada por el promedio de exámenes cortos. El 25.25% restante de la variabilidad se debe a otros factores no incluidos en el modelo, por lo tanto, aunque los exámenes cortos representan una parte pequeña de la nota, sí tienen una relación considerable con el resultado final del estudiante.
6. Obtenga la recta de regresión ajustada y grafíquelo sobre el gráfico de dispersión.
7. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de regresión ajustada (b_1) El verdadero valor de la pendiente se encuentra entre 0.4192 y 0.8671. Por cada punto adicional en el promedio de exámenes cortos, el promedio final aumenta entre 0.42 y 0.87 puntos. Como el intervalo no incluye el valor cero, se concluye que la pendiente es significativa con respecto a que existe una relación real entre el promedio de exámenes cortos y el promedio final.
8. Calcule los residuales y trace un nuevo gráfico de dispersión. Comente, ¿Parece que se verifican los supuestos? la linealidad se cumple, ya que no muestra ninguna tendencia con los residuos.
9. Realice la prueba de Shapiro para los residuales y comente el resultado. Con el valor calculado en la prueba de shapiro que es mayor a α , nos dice que los residuos siguen una distribución normal.
10. Realice la prueba de Brausch-Pagan para los residuales y comente el resultado. el valor obtenido con esta prueba es mayor a α , lo cual quiere decir que no hay heterocedasticidad, sino homocedasticidad.
11. Tres estudiantes sacaron 70, 75 y 84 de calificación. Según la recta de regresión ajustada, ¿cuáles son los resultados esperados para estos tres alumnos? $y = 24.526822 + 0.643180(70) = 69.55$ $y = 24.526822 + 0.643180(75) = 72.77$ $y = 24.526822 + 0.643180(84) = 78.55$
12. Realice una tabla ANOVA e interprete el resultado. Valor P menor que el nivel de significancia de 0.05, por lo que se rechaza la hipótesis nula. Esto indica que existe una relación lineal significativa entre el promedio de exámenes cortos y el promedio final, confirmando que el modelo de regresión ajustado es válido para explicar el comportamiento de la calificación final en función de los exámenes cortos.

```
import pandas as pd
link_csv = "https://raw.githubusercontent.com/Aracely-26/EstadisticaInferencial2026A/refs/heads/main/Unidad01/problemario/datos_problema_01"
df = pd.read_csv(link_csv)
df
```

	Promedio_de_examenes_cortos	Promedio_final
0	59	64
1	92	84
2	72	77
3	90	80
4	95	77
5	87	81
6	89	80

	Promedio_de_examenes_cortos	Promedio_final
7	77	84
8	76	80
9	65	69
10	97	83
11	42	40
12	94	78
13	62	65
14	91	90

```
x = df['Promedio_de_examenes_cortos'] # variable independiente
y = df['Promedio_final'] # variable dependiente
```

1. Establezca una variable dependiente (Y) y una variable independiente (X). x es el promedio de los exámenes y y es el promedio final

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=200         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="*",      # forma
    color='red',     # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=50,           # tamaño de los puntos
    label='Promedio final' # etiqueta para la leyenda
)

# --- Título ---
plt.title(
    'Gráfico de dispersión de calificaciones',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Exámenes cortos',
    fontsize=12
)

plt.ylabel(
    'Promedio final',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)
```

```

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False) # superior

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion.png",
    bbox_inches='tight'
)

plt.show()

```



1. Diagrama de dispersion

1. Sí, los datos soportan la suposición de linealidad. En el diagrama se observa que los puntos siguen una tendencia ascendente constante, a pesar de notarse un inicio de u=curvatura en el lado derecho, no es suficiente para asumir que es sistemática, por tanto, no se descarta la linealidad. Esto indica que una línea recta es un modelo adecuado para describir la relación entre el promedio de exámenes cortos y el promedio final.

```
from scipy.stats import pearsonr
```

```
# Test de Pearson
```

```
# H0: rho = 0      (No hay correlación)
```

```
# H1: rho ≠ 0      (Sí hay correlación)
```

```
# alpha = 0.05
```

```
r, valor_p = pearsonr(x, y)
```

```
print(f"Coeficiente de correlación: {r: 0.4f}")
```

```
print(f'Valor p: {valor_p: 0.4f}')
```

```
Coeficiente de correlación: 0.8646
```

```
Valor p: 0.0000
```

El coeficiente de correlación obtenido es de 0.8646, lo que indica una correlación positiva y fuerte entre el promedio de exámenes cortos y el promedio final. A medida que aumenta el promedio de exámenes cortos, el promedio final también tiende a aumentar. Este resultado es consistente con el patrón ascendente observado en el diagrama de dispersión.

```
import statsmodels.api as sm
```

```
x_constante = sm.add_constant(x)
```

```
modelo = sm.OLS(y, x_constante).fit()
```

```
y_calculada = modelo.predict(x_constante)
```

```
modelo.params
```

	0	
const	24.526822	
Promedio_de_exámenes_cortos	0.643180	

dtype: float64

$$\hat{y} = 24.526822 + 0.643180x$$

donde

- $\hat{y}$ es el promedio final calculado ppor el modelo
- x es el promedio de exámenes cortos

por cada punto en examen cortos, gana 0.64 puntos en promedio final

```
modelo.predict([1,80])
```

```
array([75.98121056])
```

```
import matplotlib.pyplot as plt
```

```
# --- Configuración general del gráfico ---
```

```
plt.figure(
```

```
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
```

```
    dpi=120 # resolución del gráfico
```

```

)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",          # forma
    color='blue',        # color de los puntos
    edgecolor='black',    # borde de los puntos
    alpha=0.8,           # transparencia
    s=30,                # tamaño de los puntos
    label='promedio final' # etiqueta para la leyenda
)

# --- Gráfico de línea ---
plt.plot(
    x, y_calculada,
    color='black',        # color de la línea
    linewidth=1.0,        # grosor de la línea
    linestyle='--',       # estilo de línea
    marker='o',           # marcador en cada punto
    markersize=0,         # tamaño del marcador
    markerfacecolor='white',
    markeredgecolor='black',
    label='Recta de regresión'
)

# --- Título ---
plt.title(
    '',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'exámenes cortos',
    fontsize=12
)

plt.ylabel(
    'promedio final',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)

```

```


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_linea.png",
    bbox_inches='tight'
)

plt.show()

```



```

from sklearn.metrics import r2_score # recomendada
r2 = r2_score(y, y_calculada)
print(f'Coeficiente de determinación: {r2: 0.2%}\n')

```

Coeficiente de determinación: 74.75%

es $R^2 = 74.75\%$ El coeficiente de determinación obtenido fue de 74.75%, lo que indica que el 74.75% de la variabilidad en el promedio final de los estudiantes puede ser explicada por el promedio de exámenes cortos. El 25.25% restante de la variabilidad se debe a otros factores no incluidos en el modelo, por lo tanto, aunque los exámenes cortos representan una parte pequeña de la nota, sí tienen una relación considerable con el resultado final del estudiante.

```
# intervalo de confianza = 1 - alpha
```

```
modelo.conf_int(alpha = 0.05)
```

	0	1
const	6.441997	42.611646
Promedio_de_exámenes_cortos	0.419219	0.867141

El verdadero valor de la pendiente se encuentra entre 0.4192 y 0.8671. Por cada punto adicional en el promedio de exámenes cortos, el promedio final aumenta entre 0.42 y 0.87 puntos. Como el intervalo no incluye el valor cero, se concluye que la pendiente es significativa con respecto a que existe una relación real entre el promedio de exámenes cortos y el promedio final.

```
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns
```

```
residuos = modelo.resid
```

```
# Prueba de Shapiro-Wilk
```

```
stat, valor_p_sh = shapiro(residuos)
```

```
print(f"valor-p (Shapiro) = {valor_p_sh}")
```

```
# Visualización: Q-Q plot
```

```
sm.qqplot(residuos, line='s')
```

```
plt.title("Q-Q plot de residuos")
```

```
plt.show()
```



```
# Histograma
```

```
sns.histplot(residuos, kde=True)
```

```
plt.title("Histograma de residuos")
```

```
plt.show()
```

```
valor-p (Shapiro) = 0.901827735700704
```



Con el valor calculado en la prueba de shapiro que es mayor a alpha, nos dice que los residuos siguen una distribución normal.

```
import matplotlib.pyplot as plt
```

```
# --- Configuración general del gráfico ---
```

```
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)
```

```

)

# --- Gráfico de dispersión ---
plt.scatter(
    x, residuos,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='promedio final (residuales)' # etiqueta para la leyenda
)

plt.axhline(
    y=0,      # Donde está la línea horizontal
    label="Recta de regresión", # Etiqueta
    linestyle = "--", # Estilo de línea
    color = "black", # color
    linewidth=1.0,   # ancho de línea
)

# --- Título ---
plt.title(
    '',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'exámenes cortos',
    fontsize=12
)

plt.ylabel(
    'promedio final',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)

# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='lower right', # best
    frameon=True


```

```
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_residuales.png",
    bbox_inches='tight'
)

plt.show()
```



la linealidad se cumple, ya que no muestra ninguna tendencia con los residuos.

```
# Test de Breusch-Pagan
# H0: No hay heterocedasticidad (dispersión es igual en toda la recta)
# H1: Hay Heterocedasticidad (dispersión distinta a lo largo de la recta)
# alpha = 0.05
```

```
from statsmodels.stats.api import het_breuschpagan
_, valor_p_bp, _, _ = het_breuschpagan(residuos, x_constante)
print(f'valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')
```

```
valor_p de Breusch-Pagan: 0.2289
```

el valor obtenido con esta prueba es mayor a α , lo cual quiere decir que no hay heterocedasticidad, sino homocedasticidad.

```
# test de ANOVA (Analysis of Variance)
# H0:  $\beta_1 = 0$  (No hay correlación)
# H1:  $\beta_1 \neq 0$  (Sí hay correlación)
```

```
import statsmodels.api as sm
from statsmodels.formula.api import ols
# Y ~ X
modelo_lineal = ols('Promedio_final ~ Promedio_de_exámenes_cortos', data =
                    df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
Promedio_de_exámenes_cortos	1.0	1538.228959	1538.228959	38.492412	0.000032
Residual	13.0	519.504375	39.961875	NaN	NaN

Valor P menor que el nivel de significancia de 0.05, por lo que se rechaza la hipótesis nula. Esto indica que existe una relación lineal significativa entre el promedio de exámenes cortos y el promedio final, confirmando que el modelo de regresión ajustado es válido para explicar el comportamiento de la calificación final en función de los exámenes cortos.

William Hawkins, vicepresidente de personal de la International Motors, trabaja en la relación entre el salario de un trabajador y el porcentaje de ausentismo. Hawkins dividió el intervalo de salarios de International en 12 grados o niveles (1 es el menor grado, 12 el más alto) y después muestreó aleatoriamente a un grupo de trabajadores. Determinó el grado de salario de cada trabajador y el número de días que ese empleado había faltado en los últimos 3 años.

Categoría de salario	11	10	8	5	9	7	3
Ausencias	18	17	29	36	11	28	35

Categoría de salario	11	8	7	2	9	8	3
Ausencias	14	20	32	39	16	31	40

1. Establezca una variable dependiente (Y) y una variable independiente (X). $x = df['Categoría_salario']$ # variable independiente y $y = df['ausencias']$ # variable dependiente el salario se ve afectado por las ausencias, debido a que si hay ausencias, el trabajador no recibe el pago de su salario.
2. Realice un diagrama de dispersión para estos datos.
3. ¿Los datos soportan la suposición de linealidad? Sí, se observa una tendencia descendente clara: a mayor categoría de salario, menos ausencias. No se aprecia curvatura marcada en el patrón.
4. Calcule el coeficiente de correlación e interprete el resultado. existe una correlación negativa fuerte entre las variables. Esto significa que a medida que aumenta la categoría salarial, el número de ausencias tiende a disminuir. Este resultado respalda la intuición del vicepresidente: el nivel salarial está relacionado con el ausentismo.
5. Calcule el coeficiente de determinación e interprete el resultado. el 77.46% de la variabilidad en el número de ausencias es explicada por la categoría de salario mediante el modelo de regresión lineal. El 22.54% restante se debe a otros factores no incluidos en el modelo.
6. Obtenga la recta de regresión ajustada y gráfiquelo sobre el gráfico de dispersión.

$$\hat{y} = 47.4876 - 2.9587x$$

donde

- $\hat{y}$ es el promedio ausencias
- X es el promedio categoría salarios

1. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de regresión ajustada (b_1) con 95% de confianza, el verdadero efecto de la categoría salarial sobre las ausencias está entre una disminución de -3.96 y -1.95 días por cada categoría adicional. Como el intervalo no incluye el 0, la pendiente es significativamente distinta de cero.
2. Calcule los residuales y trace un nuevo gráfico de dispersión. Comente, ¿Parece que se verifican los supuestos? el análisis gráfico de los residuales apoya que los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien para este modelo de regresión lineal simple.
3. Realice la prueba de Shapiro para los residuales y comente el resultado. como $p = 0.893 > 0.05$, no se rechaza la hipótesis nula, por lo tanto, los residuales siguen una distribución aproximadamente normal.
4. Realice la prueba de Brausch-Pagan para los residuales y comente el resultado. como $p = 0.450 > 0.05$, no se rechaza la hipótesis nula, es decir, hay homocedasticidad; la varianza del error es aproximadamente constante a lo largo de todo el rango de X, lo cual es consistente con lo observado visualmente en el gráfico de residuales
5. Utiliza la recta de regresión para interpolar dos valores y extrapolar uno. Comenta estos resultados. $y = 47.4876 - 2.9587(6) = 29.74$ $y = 47.4876 - 2.9587(8) = 23.82$
 $y = 47.4876 - 2.9587(12) = 11.98$
6. Realice una tabla ANOVA e interprete el resultado. el p es mucho menor que 0.05, por lo que se rechaza la hipótesis nula. El modelo de regresión es estadísticamente significativo: la categoría de salario tiene un efecto real sobre el número de ausencias.

```
import pandas as pd
link_csv = "https://raw.githubusercontent.com/Aracely-26/EstadisticaInferencial2026A/refs/heads/main/Unidad01/problematario/datos_problema_01"
df = pd.read_csv(link_csv)
df
```

	Categoria_salario	ausencias
0	11	18
1	10	17
2	8	29
3	5	36
4	9	11
5	7	28
6	3	35
7	11	14
8	8	20
9	7	32
10	2	39
11	9	16
12	8	31
13	3	40

```
x = df['Categoria_salario'] # variable independiente
y = df['ausencias'] # variable dependiente
```

el salario se ve afectado por las ausencias, debido a que si hay ausencias, el trabajador no recibe el pago de sus salario.

```

import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4),    # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120            # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",        # forma
    color='blue',      # color de los puntos
    edgecolor='black',  # borde de los puntos
    alpha=0.8,         # transparencia
    s=50,              # tamaño de los puntos
    label='Ausencias'  # etiqueta para la leyenda
)

# --- Título ---
plt.title(
    'Gráfico de dispersión',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Categoria salario',
    fontsize=12
)

plt.ylabel(
    'Ausencias',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)

# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,

```


```

'',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion.png",
    bbox_inches='tight'
)

plt.show()

```



se observa una tendencia descendente clara: a mayor categoría de salario, menos ausencias. No se aprecia curvatura marcada en el patrón.

```

from scipy.stats import pearsonr

# Test de Pearson
# H0: rho = 0      (No hay correlación)
# H1: rho ≠ 0     (Sí hay correlación)
# alpha = 0.05

r, valor_p = pearsonr(x, y)

print(f"Coeficiente de correlación: {r: 0.4f}")
print(f'Valor p: {valor_p: 0.4f}')

Coeficiente de correlación: -0.8801
Valor p: 0.0000

```

existe una correlación negativa fuerte entre las variables. Esto significa que a medida que aumenta la categoría salarial, el número de ausencias tiende a disminuir. Este resultado respalda la intuición del vicepresidente: el nivel salarial está relacionado con el ausentismo.

```
import statsmodels.api as sm
x_constante = sm.add_constant(x)
modelo = sm.OLS(y, x_constante).fit()
y_calculada = modelo.predict(x_constante)

modelo.params
```

	0	
const	47.487603	
Categoria_salario	-2.958678	

dtype: float64

$$\hat{y} = 47.4876 - 2.9587x$$

donde

- $\hat{y}$ es el promedio ausencias
- X es el promedio categoria salarios

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='' # etiqueta para la leyenda
)

# --- Gráfico de línea ---
plt.plot(
    x, y_calculada,
    color='black',   # color de la línea
    linewidth=1.0,   # grosor de la línea
    linestyle='--',  # estilo de línea
    marker='o',      # marcador en cada punto
    markersize=0,    # tamaño del marcador
    markerfacecolor='white',
    markeredgecolor='black',
    label='Recta de regresión'
)

# --- Título ---
plt.title(
    'Dispersion recta de regresion',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Categoria salarios',
```

```

        fontsize=12
    )

plt.ylabel(
    'Ausencias',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_linea.png",
    bbox_inches='tight'
)

plt.show()

```



```
from sklearn.metrics import r2_score # recomendada
r2 = r2_score(y, y_calculada)
print(f'Coeficiente de determinación: {r2: 0.2%}\n')
```

Coeficiente de determinación: 77.46%

el 77.46% de la variabilidad en el número de ausencias es explicada por la categoría de salario mediante el modelo de regresión lineal. El 22.54% restante se debe a otros factores no incluidos en el modelo.

```
# intervalo de confianza = 1 - alpha
```

```
modelo.conf_int(alpha = 0.05)
```

	0	1
const	39.707750	55.267457
Categoria_salario	-3.962455	-1.954900

con 95% de confianza, el verdadero efecto de la categoría salarial sobre las ausencias está entre una disminución de -3.96 y -1.95 días por cada categoría adicional. Como el intervalo no incluye el 0, la pendiente es significativamente distinta de cero.

```
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo.resid

# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")

# Visualización: Q-Q plot
```



```

sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()

valor-p (Shapiro) = 0.8932566424098969

```



omo $p = 0.893 > 0.05$, no se rechaza la hipótesis nula, por lo tanto, los residuales siguen una distribución aproximadamente normal.

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, residuos,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='Ausencias (residuales)' # etiqueta para la leyenda
)

plt.axhline(
    y=0, # Donde está la línea horizontal
    label="Recta de regresión", # Etiqueta
    linestyle="--", # Estilo de línea
    color="black", # color
    linewidth=1.0, # ancho de línea
)

# --- Título ---
plt.title(
    '',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Categoría salarios',
    fontsize=12
)

plt.ylabel(
    'Ausencias',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
```

```

    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='lower right', # best
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_residuales.png",
    bbox_inches='tight'
)

plt.show()

```



el análisis gráfico de los residuales apoya que los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien para este modelo de regresión lineal simple.

```

# Test de Breusch-Pagan
# H0: No hay heterocedasticidad (dispersión es igual en toda la recta)
# H1: Hay Heterocedasticidad (dispersión distinta a lo largo de la recta)
# alpha = 0.05

```

```

from statsmodels.stats.api import het_breuschpagan

```

```
_, valor_p_bp, _, _ = het_breuschpagan(residuos, x_constante)
print(f'valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')
```

valor_p de Breusch-Pagan: 0.4505

como $p = 0.450 > 0.05$, no se rechaza la hipótesis nula, es decir, hay homocedasticidad; la varianza del error es aproximadamente constante a lo largo de todo el rango de X , lo cual es consistente con lo observado visualmente en el gráfico de residuales

```
# test de ANOVA (Analysis of Variance)
# H0: beta_1 = 0 (No hay correlación)
# H1: beta_1 != 0 (Sí hay correlación)

import statsmodels.api as sm
from statsmodels.formula.api import ols
# Y ~ X
modelo_lineal = ols('Categoria_salario~ausencias', data = df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
ausencias	1.0	87.034348	87.034348	41.243954	0.000033
Residual	12.0	25.322795	2.110233	NaN	NaN

el p es mucho menor que 0.05, por lo que se rechaza la hipótesis nula. El modelo de regresión es estadísticamente significativo: la categoría de salario tiene un efecto real sobre el número de ausencias.

Problema 3

A menudo, quienes hacen la contabilidad de costos estiman los gastos generales con base en el nivel de producción. En Standard Knitting Co. han reunido información acerca de los gastos generales y las unidades producidas en diferentes plantas.

Gastos generales	191	170	272	155	280	173	234	116	153	178
Unidades	40	42	53	35	56	39	48	30	37	40

1. Establezca una variable dependiente (Y) y una variable independiente (X). Las unidades producidas es lo que determina o predice el gasto general, no al revés.
2. Realice un diagrama de dispersión para estos datos.
3. ¿Los datos soportan la suposición de linealidad? Se observa una tendencia ascendente muy marcada y recta; a mayor número de unidades producidas, mayores gastos generales, sin ninguna curvatura visible en el patrón.
4. Calcule el coeficiente de correlación e interprete el resultado. existe una correlación lineal positiva muy fuerte entre las unidades producidas y los gastos generales. Esto indica que a mayor producción, mayores son los gastos generales de manera consistente.
5. Calcule el coeficiente de determinación e interprete el resultado. el 96.73% de la variabilidad en los gastos generales es explicada por las unidades producidas mediante el modelo de regresión lineal. Solo el 3.27% se debe a otros factores no incluidos en el modelo.
6. Obtenga la recta de regresión ajustada y grafíquelo sobre el gráfico de dispersión. $y = -80.442857 + 6.491497x$ donde

- $\hat{y}$ es el promedio gastos generales

- X es el promedio unidades Por cada unidad producida, los gastos aumenta en promedio 6.49
1. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de regresión ajustada (b_1) Se estima que el verdadero valor de la pendiente poblacional se encuentra entre 5.518 y 7.465. Por cada unidad adicional producida, los gastos generales aumentan entre 5.52 y 7.46, en promedio. Dado que este intervalo no incluye el valor cero, se concluye que la pendiente es estadísticamente significativa, es decir, existe una relación real y positiva entre las unidades producidas y los gastos generales.
 2. Calcule los residuales y trace un nuevo gráfico de dispersión. Comente, ¿Parece que se verifican los supuestos? el análisis gráfico de los residuales apoya que los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien para este modelo de regresión lineal simple.
 3. Realice la prueba de Shapiro para los residuales y comente el resultado. como $p = 0.220 > 0.05$, no se rechaza la hipótesis nula. Los residuales siguen una distribución aproximadamente normal.
 4. Realice la prueba de Brausch-Pagan para los residuales y comente el resultado. como $p = 0.986 > 0.05$, no se rechaza la hipótesis nula, es decir, hay homocedasticidad. Hay fuerte evidencia de que la varianza del error es constante a lo largo de X .
 5. Utiliza la recta de regresión para interpolar dos valores y extrapolar uno. Comenta estos resultados. $y = -80.442857 + 6.491497(33) = 133.76$
 $y = -80.442857 + 6.491497(44) = 205.19$ $y = -80.442857 + 6.491497(65) = 341.48$
 6. Realice una tabla ANOVA e interprete el resultado. el P es extremadamente pequeño, mucho menor que 0.05, por lo que se rechaza la hipótesis nula. El modelo es altamente significativo: las unidades producidas explican de forma muy sólida los gastos generales, confirmando la práctica común de contabilidad de costos de estimar gastos generales con base en el nivel de producción.

```
import pandas as pd
link_csv = "https://raw.githubusercontent.com/Aracely-26/EstadisticaInferencial2026A/refs/heads/main/Unidad01/problematario/datos_problema_0:
df = pd.read_csv(link_csv)
df
```

	Gastos_generales	Unidades
0	191	40
1	170	42
2	272	53
3	155	35
4	280	56
5	173	39
6	234	48
7	116	30
8	153	37
9	178	40

```
x = df['Unidades'] # variable independiente
y = df['Gastos_generales'] # variable dependiente
```

Las unidades producidas es lo que determina o predice el gasto general, no al revés.

```
import matplotlib.pyplot as plt
```

```

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4),    # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120            # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",        # forma
    color='blue',      # color de los puntos
    edgecolor='black',  # borde de los puntos
    alpha=0.8,         # transparencia
    s=50,              # tamaño de los puntos
    label='Gastos generales' # etiqueta para la leyenda
)

# --- Título ---
plt.title(
    'Gráfico de dispersión',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Unidades',
    fontsize=12
)

plt.ylabel(
    'Gastos generales',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)

# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,

```


```

        ha='left',
        va='center',
        transform=plt.gca().transAxes
    )

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion.png",
    bbox_inches='tight'
)

plt.show()

```



Se observa una tendencia ascendente muy marcada y recta; a mayor número de unidades producidas, mayores gastos generales, sin ninguna curvatura visible en el patrón.

```

from scipy.stats import pearsonr

# Test de Pearson
# H0: rho = 0      (No hay correlación)
# H1: rho ≠ 0     (Sí hay correlación)
# alpha = 0.05

r, valor_p = pearsonr(x, y)

print(f"Coeficiente de correlación: {r: 0.4f}")
print(f'Valor p: {valor_p: 0.4f}')

```

Coeficiente de correlación: 0.9835
 Valor p: 0.0000

existe una correlación lineal positiva muy fuerte entre las unidades producidas y los gastos generales. Esto indica que a mayor producción, mayores son los gastos generales de manera consistente.

```

import statsmodels.api as sm
x_constante = sm.add_constant(x)
modelo = sm.OLS(y, x_constante).fit()

```

```
y_calculada = modelo.predict(x_constante)
```

```
modelo.params
```

	0
const	-80.442857
Unidades	6.491497

dtype: float64

$$\hat{y} = -80.442857 + 6.491497x$$

donde

- $\hat{y}$ es el promedio gastos generales
- X es el promedio unidades

Por cada unidad producida, los gastos aumenta en promedio 6.49

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",          # forma
    color='blue',        # color de los puntos
    edgecolor='black',    # borde de los puntos
    alpha=0.8,           # transparencia
    s=30,                # tamaño de los puntos
    label='Gastos generales' # etiqueta para la leyenda
)

# --- Gráfico de línea ---
plt.plot(
    x, y_calculada,
    color='black',        # color de la línea
    linewidth=1.0,        # grosor de la línea
    linestyle='--',       # estilo de línea
    marker='o',           # marcador en cada punto
    markersize=0,         # tamaño del marcador
    markerfacecolor='white',
    markeredgecolor='black',
    label='Recta de regresión'
)

# --- Título ---
plt.title(
    'Dispersion recta de regresion',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Unidades',
    fontsize=12
```

```

)

plt.ylabel(
    'Gastos generales',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False) # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_linea.png",
    bbox_inches='tight'
)

plt.show()

```



```
from sklearn.metrics import r2_score # recomendada
r2 = r2_score(y, y_calculada)
print(f'Coeficiente de determinación: {r2: 0.2%}\n')
```

Coeficiente de determinación: 96.73%

el 96.73% de la variabilidad en los gastos generales es explicada por las unidades producidas mediante el modelo de regresión lineal. Solo el 3.27% se debe a otros factores no incluidos en el modelo.

```
# intervalo de confianza = 1 - alpha
```

```
modelo.conf_int(alpha = 0.05)
```

	0	1
const	-121.986373	-38.899341
Unidades	5.518450	7.464543

Se estima que el verdadero valor de la pendiente poblacional se encuentra entre 5.518 y 7.465. Por cada unidad adicional producida, los gastos generales aumentan entre 5.52 y 7.46, en promedio. Dado que este intervalo no incluye el valor cero, se concluye que la pendiente es estadísticamente significativa, es decir, existe una relación real y positiva entre las unidades producidas y los gastos generales.

```
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")
```

```
# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()

valor-p (Shapiro) = 0.22045077017698533
```





el análisis gráfico de los residuales apoya que los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien para este modelo de regresión lineal simple.

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, residuos,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='Gastos Generales (residuales)' # etiqueta para la leyenda
)

plt.axhline(
    y=0, # Donde está la línea horizontal
    label="Recta de regresión", # Etiqueta
    linestyle="--", # Estilo de línea
    color="black", # color
    linewidth=1.0, # ancho de línea
)

# --- Título ---
plt.title(
    '',
    fontsize=14,
    fontweight='bold'
)
```

```

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Unidades',
    fontsize=12
)

plt.ylabel(
    'Gastos generales',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='lower right', # best
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_residuales.png",
    bbox_inches='tight'
)

plt.show()

```



el análisis gráfico de los residuales apoya que los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien para este modelo de regresión lineal simple.

```
# Test de Breusch-Pagan
# H0: No hay heterocedasticidad (dispersión es igual en toda la recta)
# H1: Hay Heterocedasticidad (dispersión distinta a lo largo de la recta)
# alpha = 0.05
```

```
from statsmodels.stats.api import het_breuschpagan
_, valor_p_bp, _, _ = het_breuschpagan(residuos, x_constante)
print(f'valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')
```

valor_p de Breusch-Pagan: 0.9858

como $p = 0.986 > 0.05$, no se rechaza la hipótesis nula, es decir, hay homocedasticidad. Hay fuerte evidencia de que la varianza del error es constante a lo largo de X.

```
# test de ANOVA (Analysis of Variance)
# H0: beta_1 = 0 (No hay correlación)
# H1: beta_1 ≠ 0 (Sí hay correlación)
```

```
import statsmodels.api as sm
from statsmodels.formula.api import ols
# Y ~ X
modelo_lineal = ols('Unidades ~ Gastos_generales', data = df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
Gastos_generales	1.0	568.774067	568.774067	236.669535	3.167080e-07
Residual	8.0	19.225933	2.403242	NaN	NaN

el P es extremadamente pequeño, mucho menor que 0.05, por lo que se rechaza la hipótesis nula. El modelo es altamente significativo: las unidades producidas explican de forma muy sólida los gastos generales, confirmando la práctica común de contabilidad de costos de estimar gastos generales con base en el nivel de producción.

Problema 4

Las ventas de línea blanca varían según el estado del mercado de casas nuevas: cuando las ventas de casas nuevas son buenas, también lo son las de lavaplatos, lavadoras de ropa, secadoras y refrigeradores. Una asociación de comercio compiló los siguientes datos históricos (en miles de unidades) de las ventas de línea blanca y la construcción de casas.

Construcción de casas (miles)	Ventas de línea blanca (miles)
2.0	5.0
2.5	5.5
3.2	6.0
3.6	7.0
3.7	7.2
4.0	7.7
4.2	8.4
4.6	9.0
4.8	9.7
5.0	10.0

1. Establezca una variable dependiente (Y) y una variable independiente (X). La variable independiente es la construcción de casas y la variable dependiente es las ventas de línea blanca. Se elige así porque el texto plantea que las ventas de línea blanca dependen del estado del mercado de casas nuevas, es decir, la construcción de casas es la que influye o predice el comportamiento de las ventas de electrodomésticos.
2. Realice un diagrama de dispersión para estos datos.
3. ¿Los datos soportan la suposición de linealidad? Sí, los datos soportan la suposición de linealidad. En el diagrama de dispersión se observa una tendencia ascendente muy clara y consistente, sin curvatura visible, por lo que es razonable ajustar un modelo de regresión lineal.
4. Calcule el coeficiente de correlación e interprete el resultado. el coeficiente de correlación obtenido es de 0.98, lo que indica una correlación positiva muy fuerte (casi perfecta) entre la construcción de casas y las ventas de línea blanca. Esto significa que, cuando el mercado de casas nuevas está en buen estado (más construcción), las ventas de electrodomésticos también aumentan de manera muy consistente.
5. Calcule el coeficiente de determinación e interprete el resultado. El coeficiente de determinación indica que el 96.19% de la variabilidad en las ventas de línea blanca es explicada por la construcción de casas nuevas mediante el modelo de regresión lineal. Solo el 3.81% restante se debe a otros factores no incluidos en el modelo, lo que confirma que la construcción de casas es un predictor muy sólido de las ventas de línea blanca.
6. Obtenga la recta de regresión ajustada y grafíquelo sobre el gráfico de dispersión.

$$\hat{y} = 1.0168 + 1.7376x$$

donde

- $\hat{y}$ Ventas de línea blanca
- X Construcción de casas

1. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de regresión ajustada (b_1) Con un 95% de confianza, se estima que el verdadero valor de la pendiente se encuentra entre 1.4557 y 2.0194. Como este intervalo no incluye el cero, se concluye que la pendiente es estadísticamente significativa, es decir, sí existe una relación real entre ambas variables.
2. Calcule los residuales y trace un nuevo gráfico de dispersión. Comente, ¿Parece que se verifican los supuestos? los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien, aunque el leve patrón.
3. Realice la prueba de Shapiro para los residuales y comente el resultado. Valor P mayor que 0.05, no se rechaza la hipótesis nula de normalidad. Por lo tanto, se concluye que los residuales siguen una distribución aproximadamente normal.
4. Realice la prueba de Brausch-Pagan para los residuales y comente el resultado. el valor P es mayor que 0.05, no se rechaza la hipótesis nula de homocedasticidad. Esto indica que no hay evidencia de que la varianza de los residuales cambie en función de la construcción de casas, por lo que se cumple el supuesto de varianza constante.
5. Utiliza la recta de regresión para interpolar dos valores y extrapolar uno. Comenta estos resultados. $y=1.0168+1.7376(2.8)=5.88$ $y=1.0168+1.7376(4.5)=8.83$ $y=1.0168+1.7376(7)=13.19$
6. Realice una tabla ANOVA e interprete el resultado. valor P mucho menor que alpha, por lo que se rechaza la hipótesis nula. Esto confirma que existe una relación lineal significativa entre la construcción de casas y las ventas de línea blanca, respaldando la idea de que el mercado de casas nuevas es un buen predictor de las ventas de electrodomésticos.

```
import pandas as pd
link_csv = "https://raw.githubusercontent.com/Aracely-26/EstadisticaInferencial2026A/refs/heads/main/Unidad01/problemario/datos_problema_04"
df = pd.read_csv(link_csv)
df
```

	Construcción_de_casas_miles	Ventas_de_línea_blanca_miles
0	2.0	5.0
1	2.5	5.5
2	3.2	6.0
3	3.6	7.0
4	3.7	7.2
5	4.0	7.7
6	4.2	8.4
7	4.6	9.0
8	4.8	9.7
9	5.0	10.0

```
x= df['Construcción_de_casas_miles'] # independiente
y= df['Ventas_de_línea_blanca_miles']# dependiente
```

La variable independiente es la construcción de casas y la variable dependiente es las ventas de línea blanca. Se elige así porque el texto plantea que las ventas de línea blanca dependen del estado del mercado de casas nuevas, es decir, la construcción de casas es la que influye o predice el comportamiento de las ventas de electrodomésticos.

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure()
```

```

        figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
        dpi=120         # resolución del gráfico
    )

    # --- Gráfico de dispersión ---
    plt.scatter(
        x, y,
        marker="o",      # forma
        color='blue',    # color de los puntos
        edgecolor='black', # borde de los puntos
        alpha=0.8,       # transparencia
        s=50,            # tamaño de los puntos
        label='Ventas de línea blanca miles' # etiqueta para la leyenda
    )

    # --- Título ---
    plt.title(
        'Gráfico de dispersión',
        fontsize=14,
        fontweight='bold'
    )

    # --- Etiquetas de los ejes ---
    plt.xlabel(
        'Construcción de casas miles',
        fontsize=12
    )

    plt.ylabel(
        'Ventas de línea blanca miles',
        fontsize=12
    )

    # --- Fuente de los ticks ---
    plt.xticks(fontsize=10)
    plt.yticks(fontsize=10)

    # --- Márgenes ---
    plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
    plt.gca().spines['right'].set_visible(False) # derecha
    plt.gca().spines['top'].set_visible(False)   # superior

    # --- Cuadrícula (opcional, pero didáctica) ---
    plt.grid(
        visible=True,
        linestyle='--',
        linewidth=0.7,
        alpha=0.1,
        color="gray"
    )

    # --- Leyenda ---
    plt.legend(
        fontsize=10,
        loc='best',
        frameon=True
    )

    # --- Nota al pie ---
    plt.text(
        0.4, -0.2,
        '',
        fontsize=8,
        ha='left',
        va='center',

```


```

        transform=plt.gca().transAxes
    )

    # --- Guardar gráfico ---
    plt.savefig(
        "grafico_dispersion.png",
        bbox_inches='tight'
    )

plt.show()

```



Sí, los datos soportan la suposición de linealidad. En el diagrama de dispersión se observa una tendencia ascendente muy clara y consistente, sin curvatura visible, por lo que es razonable ajustar un modelo de regresión lineal.

```

from scipy.stats import pearsonr

# Test de Pearson
# H0: rho = 0      (No hay correlación)
# H1: rho ≠ 0     (Sí hay correlación)
# alpha = 0.05

r, valor_p = pearsonr(x, y)

print(f"Coeficiente de correlación: {r: 0.4f}")
print(f'Valor p: {valor_p: 0.4f}')

```

Coeficiente de correlación: 0.9808
 Valor p: 0.0000

el coeficiente de correlación obtenido es de 0.98, lo que indica una correlación positiva muy fuerte (casi perfecta) entre la construcción de casas y las ventas de línea blanca. Esto significa que, cuando el mercado de casas nuevas está en buen estado (más construcción), las ventas de electrodomésticos también aumentan de manera muy consistente.

```

import statsmodels.api as sm
x_constante = sm.add_constant(x)
modelo = sm.OLS(y, x_constante).fit()

```

```
y_calculada = modelo.predict(x_constante)
```

```
modelo.params
```

	0
const	1.016760
Construcción_de_casas_miles	1.737564

dtype: float64

$$\hat{y} = 1.0168 + 1.7376x$$

donde

- $\hat{y}$ Ventas de línea blanca
- X Construcción de casas

```
import matplotlib.pyplot as plt
```

```
# --- Configuración general del gráfico ---
```

```
plt.figure(  
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas  
    dpi=120         # resolución del gráfico  
)
```

```
# --- Gráfico de dispersión ---
```

```
plt.scatter(  
    x, y,  
    marker="o",      # forma  
    color='blue',    # color de los puntos  
    edgecolor='black', # borde de los puntos  
    alpha=0.8,       # transparencia  
    s=30,            # tamaño de los puntos  
    label='Ventas de línea blanca miles' # etiqueta para la leyenda  
)
```

```
# --- Gráfico de línea ---
```

```
plt.plot(  
    x, y_calculada,  
    color='black', # color de la línea  
    linewidth=1.0, # grosor de la línea  
    linestyle='--', # estilo de línea  
    marker='o',    # marcador en cada punto  
    markersize=0,  # tamaño del marcador  
    markerfacecolor='white',  
    markeredgecolor='black',  
    label='Recta de regresión'  
)
```

```
# --- Título ---
```

```
plt.title(  
    'Dispersion recta de regresion',  
    fontsize=14,  
    fontweight='bold'  
)
```

```
# --- Etiquetas de los ejes ---
```

```
plt.xlabel(  
    'Construcción de casas miles',  
    fontsize=12  
)
```

```
plt.ylabel(  
    'Ventas de línea blanca miles',  
    fontsize=12  
)
```

```

        'Ventas de la linea blanca',
        fontsize=12
    )

    # --- Fuente de los ticks ---
    plt.xticks(fontsize=10)
    plt.yticks(fontsize=10)

    # --- Márgenes ---
    plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
    plt.gca().spines['right'].set_visible(False) # derecha
    plt.gca().spines['top'].set_visible(False) # superior

    # Para eliminar márgenes completamente, usar:
    # plt.margins(0)

    # --- Cuadrícula (opcional, pero didáctica) ---
    plt.grid(
        visible=True,
        linestyle='--',
        linewidth=0.7,
        alpha=0.1,
        color="gray"
    )

    # --- Leyenda ---
    plt.legend(
        fontsize=10,
        loc='best',
        frameon=True
    )


    # --- Nota al pie ---
    plt.text(
        0.4, -0.2,
        '',
        fontsize=8,
        ha='left',
        va='center',
        transform=plt.gca().transAxes
    )

    # --- Guardar gráfico ---
    plt.savefig(
        "grafico_dispersion_linea.png",
        bbox_inches='tight'
    )

    plt.show()

```

Dispersión recta de regresión



```
from sklearn.metrics import r2_score # recomendada
r2 = r2_score(y, y_calculada)
print(f'Coeficiente de determinación: {r2: 0.2%}\n')
```

Coeficiente de determinación: 96.19%

El coeficiente de determinación indica que el 96.19% de la variabilidad en las ventas de línea blanca es explicada por la construcción de casas nuevas mediante el modelo de regresión lineal. Solo el 3.81% restante se debe a otros factores no incluidos en el modelo, lo que confirma que la construcción de casas es un predictor muy sólido de las ventas de línea blanca.

```
# intervalo de confianza = 1 - alpha
```

```
modelo.conf_int(alpha = 0.05)
```

	0	1
const	-0.074848	2.108368
Construcción_de_casas_miles	1.455693	2.019435

Con un 95% de confianza, se estima que el verdadero valor de la pendiente se encuentra entre 1.4557 y 2.0194. Como este intervalo no incluye el cero, se concluye que la pendiente es estadísticamente significativa, es decir, sí existe una relación real entre ambas variables.

```
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns

residuos = modelo.resid

# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
```

```
print(f"valor-p (Shapiro) = {valor_p_sh}")
```

```
# Visualización: Q-Q plot
```

```
sm.qqplot(residuos, line='s')
```

```
plt.title("Q-Q plot de residuos")
```

```
plt.show()
```


```
# Histograma
```


```
sns.histplot(residuos, kde=True)
```

```
plt.title("Histograma de residuos")
```

```
plt.show()
```

```
valor-p (Shapiro) = 0.8463507249054649
```





Valor P mayor que 0.05, no se rechaza la hipótesis nula de normalidad. Por lo tanto, se concluye que los residuales siguen una distribución aproximadamente normal.

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x=residuos,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='Ventas de línea blanca miles (residuales)' # etiqueta para la
    Leyenda
)

plt.axhline(
    y=0,            # Donde está la línea horizontal
    label="Recta de regresión", # Etiqueta
    linestyle="--", # Estilo de línea
    color="black",  # color
    linewidth=1.0,  # ancho de línea
)

# --- Título ---
plt.title(
    '',
    fontsize=14,
    fontweight='bold'
)
```

```

# --- Etiquetas de Los ejes ---
plt.xlabel(
    'Construccion de casas miles',
    fontsize=12
)

plt.ylabel(
    'Ventas de linea blanca miles',
    fontsize=12
)

# --- Fuente de Los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de Los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='lower right', # best
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_residuales.png",
    bbox_inches='tight'
)

plt.show()

```



los supuestos de linealidad y homocedasticidad se cumplen razonablemente bien, aunque el leve patrón.

```
# Test de Breusch-Pagan
# H0: No hay heterocedasticidad (dispersión es igual en toda la recta)
# H1: Hay Heterocedasticidad (dispersión distinta a lo largo de la recta)
# alpha = 0.05
```

```
from statsmodels.stats.api import het_breuschpagan
_, valor_p_bp, _, _ = het_breuschpagan(residuos, x_constante)
print(f'valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')
```

valor_p de Breusch-Pagan: 0.1581

el valor P es mayor que 0.05, no se rechaza la hipótesis nula de homocedasticidad. Esto indica que no hay evidencia de que la varianza de los residuales cambie en función de la construcción de casas, por lo que se cumple el supuesto de varianza constante.

```
# test de ANOVA (Analysis of Variance)
# H0: beta_1 = 0 (No hay correlación)
# H1: beta_1 != 0 (Sí hay correlación)

import statsmodels.api as sm
from statsmodels.formula.api import ols
# Y ~ X
modelo_lineal = ols('Construcción_de_casas_miles ~
                    Ventas_de_línea_blanca_miles', data = df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
Ventas_de_línea_blanca_miles	1.0	8.276338	8.276338	202.069951	5.841003e-07
Residual	8.0	0.327662	0.040958	NaN	NaN

valor P mucho menor que alpha, por lo que se rechaza la hipótesis nula. Esto confirma que existe una relación lineal significativa entre la construcción de casas y las ventas de línea blanca, respaldando la idea de que el mercado de casas nuevas es un buen predictor de las ventas de electrodomésticos.

Problema 5

William C. Andrews, consultor de comportamiento organizacional de Victory Motorcycles, ha diseñado una prueba para mostrar a los supervisores de la compañía los peligros de sobrevigilar a sus trabajadores. Un trabajador de la línea de ensamble tiene a su cargo una serie de tareas complicadas. Durante el desempeño del trabajador, un inspector lo interrumpe constantemente para ayudarlo a terminar las tareas. El trabajador, después de terminar su trabajo, recibe una prueba psicológica diseñada para medir la hostilidad del trabajador hacia la autoridad (una alta puntuación implica una hostilidad baja). A ocho distintos trabajadores se les asignaron las tareas y luego se les interrumpió para darles instrucciones útiles un número variable de veces (línea X). Sus calificaciones en la prueba de hostilidad se dan en el renglón Y.

número interrupciones al trabajador	5	10	10	15	15	20	20	25
calificación del trabajador en la prueba de hostilidad	58	41	45	27	26	12	16	3

1. Establezca una variable dependiente (Y) y una variable independiente (X). La variable independiente es el número de interrupciones al trabajador, y la variable dependiente es la calificación en la prueba de hostilidad. Se elige así porque el estudio busca ver cómo el hecho de interrumpir al trabajador (la causa, la sobrevigilancia) afecta su nivel de hostilidad hacia la autoridad (el efecto medido).
2. Realice un diagrama de dispersión para estos datos.
3. ¿Los datos soportan la suposición de linealidad? correlación negativa casi perfecta y fuerte Sí, los datos soportan la suposición de linealidad. En el diagrama de dispersión se observa una tendencia descendente muy clara y recta: a mayor número de interrupciones, menor calificación en la prueba de hostilidad. No se aprecia curvatura en el patrón.
4. Calcule el coeficiente de correlación e interprete el resultado. El coeficiente de correlación obtenido es de -0.99, lo que indica una correlación negativa casi perfecta entre el número de interrupciones y la calificación de hostilidad
5. Calcule el coeficiente de determinación e interprete el resultado. El coeficiente de determinación indica que el 98.58% de la variabilidad en la calificación de hostilidad es explicada por el número de interrupciones mediante el modelo de regresión lineal. Solo el 1.42% restante se debe a otros factores no incluidos en el modelo, lo que confirma un ajuste casi perfecto entre ambas variables.
6. Obtenga la recta de regresión ajustada y grafíquelo sobre el gráfico de dispersión.

$$\hat{y} = 70.5 - 2.8x$$

donde

- $\hat{y}$ calificación del trabajador en la prueba de hostilidad
- X número interrupciones al trabajador

1. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de regresión ajustada (b_1) Con un 95% de confianza, se estima que el verdadero valor de la pendiente se encuentra entre -3.136 y -2.464. Como este intervalo no incluye el cero, se concluye que la pendiente es estadísticamente significativa: existe una relación real y negativa entre el número de interrupciones y la calificación de hostilidad.
2. Calcule los residuales y trace un nuevo gráfico de dispersión. Comente, ¿Parece que se verifican los supuestos? el gráfico apoya fuertemente que los supuestos de linealidad y homocedasticidad se cumplen para este modelo. Este comportamiento tan ordenado de los residuales es consistente con el excelente ajuste del modelo, reflejando que el modelo lineal captura muy bien la relación entre el número de interrupciones y la calificación de hostilidad.

3. Realice la prueba de Shapiro para los residuales y comente el resultado. Valor P es mayor que 0.05, aunque muy cerca del límite, no se rechaza la hipótesis nula de normalidad. Sin embargo, este resultado debe interpretarse cuidadosamente. Se puede concluir que no hay evidencia fuerte en contra de la normalidad, pero el resultado está en el límite.
4. Realice la prueba de Brausch-Pagan para los residuales y comente el resultado. Valor P mayor que 0.05, no se rechaza la hipótesis nula de homocedasticidad. Esto indica que no hay evidencia de que la varianza de los residuales cambie en función del número de interrupciones, por lo que se cumple el supuesto de varianza constante.
5. Utiliza la recta de regresión para interpolar dos valores y extrapolar uno. Comenta estos resultados. $y=70.5-2.8(12)=37.1$ $y=70.5-2.8(22)=9.1$ $y=70.5-2.8(2)=64.9$
6. Realice una tabla ANOVA e interprete el resultado. El valor P es mucho menor que 0.05, por lo que se rechaza la hipótesis nula. Esto confirma que existe una relación lineal altamente significativa entre el número de interrupciones y la calificación de hostilidad, con lo que se confirman los riesgos de interrumpir a los trabajadores constantemente, ya que está fuertemente asociado con un aumento en su hostilidad hacia la autoridad.

```
import pandas as pd
link_csv = "https://raw.githubusercontent.com/Aracely-26/EstadisticaInferencial2026A/refs/heads/main/Unidad01/problemario/datos_problema_05.csv"
df = pd.read_csv(link_csv)
df
```

	Numero_interrupciones_al_trabajador	Calificacion_del_trabajador_en_la_prueba_de_hostilidad
0	5	58
1	10	41
2	10	45
3	15	27
4	15	26
5	20	12
6	20	16
7	25	3

```
x= df['Numero_interrupciones_al_trabajador']
y= df['Calificacion_del_trabajador_en_la_prueba_de_hostilidad']
```

La variable independiente es el número de interrupciones al trabajador, y la variable dependiente es la calificación en la prueba de hostilidad. Se elige así porque el estudio busca ver cómo el hecho de interrumpir al trabajador (la causa, la supervigilancia) afecta su nivel de hostilidad hacia la autoridad (el efecto medido).

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
)
```

```

    alpha=0.8,          # transparencia
    s=50,               # tamaño de los puntos
    label='Calificación del trabajador en la prueba de hostilidad' # etiqueta
                        para la leyenda
)

# --- Título ---
plt.title(
    'Gráfico de dispersión',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Número de interrupciones del trabajador',
    fontsize=12
)

plt.ylabel(
    'Calificación del trabajador en la prueba de hostilidad',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False)   # superior

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion.png",
    bbox_inches='tight'
)

```

```
plt.show()
```



correlación negativa casi perfecta y fuerte Sí, los datos soportan la suposición de linealidad. En el diagrama de dispersión se observa una tendencia descendente muy clara y recta: a mayor número de interrupciones, menor calificación en la prueba de hostilidad. No se aprecia curvatura en el patrón.

```
from scipy.stats import pearsonr
```

```
# Test de Pearson
```

```
# H0: rho = 0 (No hay correlación)
```

```
# H1: rho ≠ 0 (Sí hay correlación)
```

```
# alpha = 0.05
```

```
r, valor_p = pearsonr(x, y)
```

```
print(f"Coeficiente de correlación: {r: 0.4f}")
```

```
print(f'Valor p: {valor_p: 0.4f}')
```

```
Coeficiente de correlación: -0.9928
```

```
Valor p: 0.0000
```

El coeficiente de correlación obtenido es de -0.99, lo que indica una correlación negativa casi perfecta entre el número de interrupciones y la calificación de hostilidad

```
import statsmodels.api as sm
```

```
x_constante = sm.add_constant(x)
```

```
modelo = sm.OLS(y, x_constante).fit()
```

```
y_calculada = modelo.predict(x_constante)
```

```
modelo.params
```

	0
const	70.5
Numero_interrupciones_al_trabajador	-2.8

dtype: float64

$$\hat{y} = 70.5 - 2.8x$$

donde

- $\hat{y}$ 'calificación del trabajador en la prueba de hostilidad
- X número interrupciones al trabajador

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, y,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='Calificacion del trabajador en la prueba de hostilidad' # etiqueta
                        # para la leyenda
)

# --- Gráfico de línea ---
plt.plot(
    x, y_calculada,
    color='black',   # color de la línea
    linewidth=1.0,   # grosor de la línea
    linestyle='--',  # estilo de línea
    marker='o',      # marcador en cada punto
    markersize=0,    # tamaño del marcador
    markerfacecolor='white',
    markeredgecolor='black',
    label='Recta de regresión'
)

# --- Título ---
plt.title(
    'Dispersion recta de regresion',
    fontsize=14,
    fontweight='bold'
)

# --- Etiquetas de los ejes ---
plt.xlabel(
    'Numero de interrupcciones del trabajador',
    fontsize=12
)

plt.ylabel(
    'Calificacion del trabajador en la prueba de hostilida',
    fontsize=12
)

# --- Fuente de los ticks ---
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)
```

```

# --- Márgenes ---
plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
plt.gca().spines['right'].set_visible(False) # derecha
plt.gca().spines['top'].set_visible(False) # superior

# Para eliminar márgenes completamente, usar:
# plt.margins(0)

# --- Cuadrícula (opcional, pero didáctica) ---
plt.grid(
    visible=True,
    linestyle='--',
    linewidth=0.7,
    alpha=0.1,
    color="gray"
)


# --- Leyenda ---
plt.legend(
    fontsize=10,
    loc='best',
    frameon=True
)

# --- Nota al pie ---
plt.text(
    0.4, -0.2,
    '',
    fontsize=8,
    ha='left',
    va='center',
    transform=plt.gca().transAxes
)

# --- Guardar gráfico ---
plt.savefig(
    "grafico_dispersion_linea.png",
    bbox_inches='tight'
)

plt.show()

```



```
from sklearn.metrics import r2_score # recomendada
r2 = r2_score(y, y_calculada)
print(f'Coeficiente de determinación: {r2: 0.2%}\n')
```

Coeficiente de determinación: 98.58%

El coeficiente de determinación indica que el 98.58% de la variabilidad en la calificación de hostilidad es explicada por el número de interrupciones mediante el modelo de regresión lineal. Solo el 1.42% restante se debe a otros factores no incluidos en el modelo, lo que confirma un ajuste casi perfecto entre ambas variables.

```
# intervalo de confianza = 1 - alpha
```

```
modelo.conf_int(alpha = 0.05)
```

	0	1
const	65.051384	75.948616
Numero_interrupciones_al_trabajador	-3.136296	-2.463704

Con un 95% de confianza, se estima que el verdadero valor de la pendiente se encuentra entre -3.136 y -2.464. Como este intervalo no incluye el cero, se concluye que la pendiente es estadísticamente significativa: existe una relación real y negativa entre el número de interrupciones y la calificación de hostilidad.

```
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns


residuos = modelo.resid


# Prueba de Shapiro-Wilk
stat, valor_p_sh = shapiro(residuos)
print(f"valor-p (Shapiro) = {valor_p_sh}")
```

```
# Visualización: Q-Q plot
sm.qqplot(residuos, line='s')
plt.title("Q-Q plot de residuos")
plt.show()
```

```
# Histograma
sns.histplot(residuos, kde=True)
plt.title("Histograma de residuos")
plt.show()
```

valor-p (Shapiro) = 0.054816491127669634





Valor P es mayor que 0.05, aunque muy cerca del límite, no se rechaza la hipótesis nula de normalidad. Sin embargo, este resultado debe interpretarse cuidadosamente. Se puede concluir que no hay evidencia fuerte en contra de la normalidad, pero el resultado está en el límite.

```
import matplotlib.pyplot as plt

# --- Configuración general del gráfico ---
plt.figure(
    figsize=(6, 4), # tamaño de la figura (ancho, alto) en pulgadas
    dpi=120         # resolución del gráfico
)

# --- Gráfico de dispersión ---
plt.scatter(
    x, residuos,
    marker="o",      # forma
    color='blue',    # color de los puntos
    edgecolor='black', # borde de los puntos
    alpha=0.8,       # transparencia
    s=30,            # tamaño de los puntos
    label='Calificacion del trabajador en la prueba de hostilidad'
    (residuales) # etiqueta para la leyenda
)

plt.axhline(
    y=0, # Donde está la línea horizontal
    label="Recta de regresión", # Etiqueta
    linestyle = "--", # Estilo de línea
    color = "black", # color
    linewidth=1.0, # ancho de línea
)

# --- Título ---
plt.title(
    '',
    fontsize=14,
```

```

        fontweight='bold'
    )

    # --- Etiquetas de Los ejes ---
    plt.xlabel(
        'Numero de interrupciones del trabajador',
        fontsize=12
    )

    plt.ylabel(
        'Calificacion del trabajador en la prueba de hostilidad',
        fontsize=12
    )

    # --- Fuente de los ticks ---
    plt.xticks(fontsize=10)
    plt.yticks(fontsize=10)

    # --- Márgenes ---
    plt.margins(x=0.05, y=0.05) # espacio extra alrededor de los datos
    plt.gca().spines['right'].set_visible(False) # derecha
    plt.gca().spines['top'].set_visible(False) # superior

    # Para eliminar márgenes completamente, usar:
    # plt.margins(0)

    # --- Cuadrícula (opcional, pero didáctica) ---
    plt.grid(
        visible=True,
        linestyle='--',
        linewidth=0.7,
        alpha=0.1,
        color="gray"
    )


    # --- Leyenda ---
    plt.legend(
        fontsize=10,
        loc='lower right', # best
        frameon=True
    )

    # --- Nota al pie ---
    plt.text(
        0.4, -0.2,
        '',
        fontsize=8,
        ha='left',
        va='center',
        transform=plt.gca().transAxes
    )

    # --- Guardar gráfico ---
    plt.savefig(
        "grafico_dispersion_residuales.png",
        bbox_inches='tight'
    )

    plt.show()

```



el gráfico apoya fuertemente que los supuestos de linealidad y homocedasticidad se cumplen para este modelo. Este comportamiento tan ordenado de los residuales es consistente con el excelente ajuste del modelo, reflejando que el modelo lineal captura muy bien la relación entre el número de interrupciones y la calificación de hostilidad.

```
# Test de Breusch-Pagan
# H0: No hay heterocedasticidad (dispersión es igual en toda la recta)
# H1: Hay Heterocedasticidad (dispersión distinta a lo largo de la recta)
# alpha = 0.05
```

```
from statsmodels.stats.api import het_breuschpagan
_, valor_p_bp, _, _ = het_breuschpagan(residuos, x_constante)
print(f'valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')
```

valor_p de Breusch-Pagan: 0.2482

Valor P mayor que 0.05, no se rechaza la hipótesis nula de homocedasticidad. Esto indica que no hay evidencia de que la varianza de los residuales cambie en función del número de interrupciones, por lo que se cumple el supuesto de varianza constante.

```
# test de ANOVA (Analysis of Variance)
# H0: beta_1 = 0 (No hay correlación)
# H1: beta_1 ≠ 0 (Sí hay correlación)
```

```
import statsmodels.api as sm
from statsmodels.formula.api import ols
# Y ~ X
modelo_lineal = ols('Calificacion_del_trabajador_en_la_prueba_de_hostilidad
~ Numero_interrupciones_al_trabajador', data = df).fit()
tabla_anova = sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
Numero_interrupciones_al_trabajador	1.0	2352.0	2352.000000	415.058824	9.090964e-07

	df	sum_sq	mean_sq	F	PR(>F)
Residual	6.0	34.0	5.666667	NaN	NaN

El valor P es mucho menor que 0.05, por lo que se rechaza la hipótesis nula. Esto confirma que existe una relación lineal altamente significativa entre el número de interrupciones y la calificación de hostilidad, con lo que se confirman los riesgos de interrumpir a los trabajadores constantemente, ya que está fuertemente asociado con un aumento en su hostilidad hacia la autoridad.